

Caso de Arquitectura

Asistente virtual para trámites e información administrativa

Documento que consolida la propuesta, el análisis del sistema y la arquitectura inicial del asistente virtual de una entidad pública peruana con TUPA y mesa de partes.

Contenido

1. Propuesta del asistente virtual
2. Actores del sistema
3. Historias de usuario
4. Requisitos funcionales
5. Atributos de calidad
6. Restricciones del proyecto
7. Drivers arquitectónicos
8. Arquitectura inicial del sistema

1. Propuesta del asistente virtual

Fuente: propuesta.md

Propuesta: asistente virtual para trámites e información administrativa

Se tomó la estructura de WILLAKUY (contexto, contenedores, componentes del worker) y se adaptó de un canal de consultas y reclamos a un asistente que orienta, guía y da seguimiento a trámites. Se asume una entidad pública peruana con TUPA y mesa de partes. Si es otra institución, solo cambia el catálogo de trámites.

1. Contexto

El asistente es el punto único de orientación para trámites e información de la entidad. Lo usan tres actores:

- **Administrado (usuario):** consulta requisitos, costos, plazos y estado de su expediente. También recibe ayuda guiada para iniciar un trámite, por texto o voz.
- **Gestor de área:** atiende los casos que el asistente no puede resolver con certeza, valida borradores de respuesta y mantiene actualizado el catálogo de trámites de su área.
- **Autoridad o administrador:** consulta métricas de demanda, trámites más consultados, cuellos de botella y plazos vencidos.

Sistemas externos:

- WhatsApp y web como canales principales, más SMS para zonas con poca conectividad.
- Sistema de gestión documentaria o mesa de partes virtual, donde se registra el expediente y se consulta su estado.
- Proveedor gestionado de modelos de lenguaje y voz.
- Opcionales según la entidad: validación de identidad (RENIEC/PIDE) y pasarela de pagos.

Cambio principal respecto a WILLAKUY: el asistente no solo responde, también consulta el estado real del expediente y guía el llenado de requisitos. Eso introduce integración con sistemas internos y datos personales.

2. Contenedores

Contenedor	Responsabilidad
Gateway de canales	API sin estado. Recibe de todos los canales, valida, encola el mensaje y devuelve un código de seguimiento en menos de 200 ms. Es lo único en la ruta crítica del usuario.
Bus de eventos	Colas por etapa: transcripción, clasificación, respuesta, notificación. Desacopla la ingesta de la inferencia.

Contenedor	Responsabilidad
Workers de procesamiento	Transcripción de voz, clasificación y enrutamiento, y generación de respuesta con recuperación documental. Escalan por separado.
Servicio de trámites (nuevo)	Expone el catálogo TUPA estructurado (requisitos, costos, plazos, base legal, área responsable). Consulta el estado de expedientes en el sistema documentario mediante una capa anticorrupción.
Gestor de diálogo guiado (nuevo)	Máquina de estados para flujos como "quiero iniciar el trámite X": pide datos, verifica requisitos, adjunta documentos y entrega el expediente prellenado.
Aplicación web ciudadana	Interfaz accesible (WCAG) con el mismo flujo que el canal conversacional.
Backoffice institucional	Bandeja de casos derivados, aprobación de respuestas, edición del catálogo, tablero de demanda y plazos.
Servicio de notificaciones	Responde por el canal de origen y avisa cambios de estado del expediente.
Almacenamiento	Base relacional con extensión vectorial (casos y corpus normativo), caché en memoria (sesión y respuestas frecuentes) y repositorio de documentos oficiales.

3. Componentes del worker de respuesta

El flujo es el mismo de WILLAKUY, con dos agregados señalados:

- **Normalizador de texto:** limpia y unifica la entrada.
- **Clasificador de intención:** distingue entre información (requisitos, costos, horarios), iniciar trámite, consultar estado y otro. Esta distinción es nueva y define qué camino sigue la consulta.
- **Extractor de entidades:** trámite, área, número de expediente, datos de contacto.
- **Verificador de caché semántica:** evita llamadas costosas si una consulta equivalente ya fue resuelta. No se aplica a consultas de estado, porque dependen del expediente de cada persona.
- **Enrutador por intención (nuevo):**
- **Información:** sigue al recuperador.
- **Estado:** consulta el Servicio de trámites, sin pasar por el modelo generativo.
- **Iniciar trámite:** pasa al Gestor de diálogo guiado.
- **Recuperador:** consulta el corpus oficial (TUPA, directivas, TUO de la Ley 27444).
- **Generador:** redacta la respuesta con su cita normativa.
- **Evaluador de confianza:** emite automáticamente si el sustento documental es suficiente. Si no, deriva al gestor con un borrador ya redactado.

Que el estado del expediente se resuelva con datos reales y no con texto generado evita que el asistente invente información sobre casos concretos, que es el error más costoso en este dominio.

4. Atributos de calidad y decisiones clave

- **Exactitud sobre fluidez:** toda respuesta sobre requisitos o costos debe citar el documento fuente. Sin sustento, deriva a un humano.
- **Disponibilidad:** la ingesta responde aunque la inferencia esté caída, porque el bus absorbe la carga. Si el proveedor de modelos falla, el sistema responde con información del catálogo y deriva el resto.
- **Privacidad:** cumplimiento de la Ley 29733 (protección de datos personales). Se solicita consentimiento, se enmascaran DNI y datos de contacto antes de enviarlos al proveedor externo, y se define retención de conversaciones.
- **Trazabilidad:** cada respuesta guarda versión del documento citado, nivel de confianza y quién aprobó, si hubo derivación.
- **Actualización del conocimiento:** cuando cambia el TUPA, el gestor actualiza el catálogo y se reindexa el corpus sin tocar código.
- **Accesibilidad e inclusión:** voz y texto, lenguaje claro, y opción de quechua si el público lo requiere.

5. Riesgos principales

Riesgo	Mitigación
Respuesta incorrecta sobre requisitos o costos	Cita obligatoria, umbral de confianza, revisión humana en casos dudosos
Información desactualizada	Versionado del catálogo y alertas de vigencia
Filtración de datos personales	Enmascarado, cifrado, acuerdos con el proveedor
Integración frágil con el sistema documentario	Capa anticorrupción, caché de estados y degradación controlada
Baja adopción	Canal WhatsApp, flujos cortos, indicadores de satisfacción

6. Implementación por fases

- **Fase 1, información:** consultas sobre trámites frecuentes con cita normativa.
- **Fase 2, estado:** consulta de expedientes e integración con el sistema documentario.
- **Fase 3, trámite guiado:** prellenado de requisitos y envío a mesa de partes.
- **Fase 4, analítica:** tablero para autoridades y mejora continua del catálogo.

2. Actores del sistema

Fuente: analisis-de-sistema/01-actores.md

Actores del sistema

Este documento identifica los actores (personas, organizaciones o sistemas externos) que interactúan con el asistente virtual de trámites e información administrativa.

Actores

Actor	Descripción	¿Qué necesita realizar?
Administrado	Persona (ciudadano o empresa) que realiza trámites y consulta información ante la entidad.	Consultar requisitos, costos y plazos de los trámites del TUPA, consultar el estado de su expediente e iniciar un trámite con ayuda guiada, por texto o voz.
Gestor de área	Servidor público asignado a un área de la entidad que mantiene actualizado el catálogo de trámites y resuelve los casos derivados por el asistente.	Atender casos derivados, validar y aprobar borradores de respuesta, actualizar requisitos y documentos normativos de su área y supervisar la calidad de las respuestas automáticas.
Autoridad o administrador	Funcionario con visión institucional que monitorea la demanda y el desempeño del servicio.	Consultar indicadores de demanda, trámites más consultados, cuellos de botella, plazos vencidos y nivel de satisfacción del administrado.
Sistema de gestión documentaria	Sistema externo (mesa de partes virtual o trámite documentario) donde se registran los expedientes y se consulta su estado.	Registrar expedientes y sus documentos asociados, así como exponer el estado y la trazabilidad de cada expediente.
Canales de atención	Sistemas externos que reciben y entregan mensajes al administrado. Incluyen WhatsApp, aplicación web y SMS.	Transportar los mensajes entre el administrado y su backend, entregando confirmaciones y respuestas.
Proveedor de modelos de lenguaje y voz	Servicio gestionado externo que provee capacidades de transcripción de voz y generación de texto.	Recibir texto o audio y devolver resultados estructurados (intención, entidades, respuesta redactada), cumpliendo los acuerdos de confidencialidad.
RENIEC / PIDE (opcional)	Servicio externo de validación de identidad del administrado, cuando la entidad lo requiere.	Validar la identidad del administrado cuando un trámite lo exige.

Actor	Descripción	¿Qué necesita realizar?
Pasarela de pagos (opcional)	Servicio externo para el cobro de tasas administrativas cuando el trámite lo requiere.	Procesar pagos de tasas y devolver el comprobante al sistema.

3. Historias de usuario

Fuente: analisis-de-sistema/02-historias-del-usuario.md

Historias de usuario

Las historias de usuario describen las principales necesidades desde la perspectiva de quien utilizará el sistema, siguiendo el formato:

Como **[actor]**, quiero **[acción]**, para **[beneficio]**.

Listado de historias de usuario

ID	Historia de usuario
HU01	Como administrado, quiero consultar los requisitos, costos y plazos de un trámite, para saber qué necesito antes de iniciar el procedimiento.
HU02	Como administrado, quiero recibir orientación paso a paso para iniciar un trámite, para completarlo correctamente y reducir errores en la presentación.
HU03	Como administrado, quiero consultar el estado de mi expediente, para saber en qué etapa se encuentra y qué pasos siguen.
HU04	Como administrado, quiero interactuar con el asistente por texto o voz desde WhatsApp, para usarlo desde mi celular sin necesidad de acudir presencialmente.
HU05	Como administrado, quiero recibir una respuesta con la cita del documento que respalda la información, para confiar en lo que me indica el asistente.
HU06	Como administrado, quiero ser atendido por un gestor cuando el asistente no tiene certeza, para resolver casos que requieren criterio humano.
HU07	Como gestor de área, quiero recibir en mi bandeja los casos derivados con un borrador de respuesta, para revisarlos y aprobarlos con menor esfuerzo.
HU08	Como gestor de área, quiero actualizar el catálogo de trámites de mi área (requisitos, costos, plazos y base legal), para mantener la información al día sin depender del área de TI.
HU09	Como gestor de área, quiero validar los borradores de respuesta generados por el asistente, para asegurar la calidad antes de que lleguen al administrado.

ID	Historia de usuario
HU10	Como autoridad o administrador, quiero consultar indicadores de demanda y trámites más consultados, para tomar decisiones sobre recursos y atención.
HU11	Como autoridad o administrador, quiero visualizar los expedientes con plazos vencidos o en riesgo, para priorizar la atención y reducir la morosidad.
HU12	Como autoridad o administrador, quiero ver indicadores de satisfacción y motivos de derivación, para mejorar continuamente el catálogo y los flujos del asistente.

4. Requisitos funcionales

Fuente: analisis-de-sistema/03-requisitos-funcionales.md

Requisitos funcionales

Los requisitos funcionales describen las funciones que el sistema debe realizar. Se obtienen a partir de las historias de usuario identificadas.

Diferencia importante

- **Historia de usuario:** expresa la necesidad desde el punto de vista del usuario.
- **Requisito funcional:** expresa lo que el sistema debe hacer para satisfacer esa necesidad.

Listado de requisitos funcionales

ID	Requisito funcional
RF01	El sistema debe permitir consultar los requisitos, costos y plazos de los trámites del catálogo TUPA.
RF02	El sistema debe permitir guiar al administrado paso a paso en el inicio de un trámite, solicitando los datos y documentos necesarios.
RF03	El sistema debe permitir consultar el estado de un expediente a partir de su número y los datos del administrado.
RF04	El sistema debe permitir atender al administrado por múltiples canales (WhatsApp, web y SMS) manteniendo el mismo flujo conversacional.
RF05	El sistema debe permitir transcribir mensajes de voz a texto para alimentar el mismo flujo de clasificación y respuesta.
RF06	El sistema debe permitir clasificar la intención del mensaje (información, iniciar trámite, consultar estado u otro) y enrutar al componente correspondiente.
RF07	El sistema debe permitir extraer entidades del mensaje (trámite, área, número de expediente, datos de contacto).
RF08	El sistema debe permitir generar respuestas sustentadas en el corpus normativo oficial (TUPA, directivas, TUO de la Ley 27444) e incluir la cita del documento.
RF09	El sistema debe permitir derivar al gestor de área, con un borrador ya redactado, cuando la confianza de la respuesta automática sea insuficiente.

ID	Requisito funcional
RF10	El sistema debe permitir al gestor de área aprobar, rechazar o editar las respuestas derivadas antes de enviarlas al administrado.
RF11	El sistema debe permitir al gestor de área actualizar el catálogo de trámites (requisitos, costos, plazos y base legal) de su área.
RF12	El sistema debe permitir registrar y consultar los expedientes generados a través del flujo guiado en el sistema de gestión documentaria.
RF13	El sistema debe permitir notificar al administrado, por el canal de origen, los cambios de estado de su expediente.
RF14	El sistema debe permitir almacenar la trazabilidad de cada respuesta (versión del documento citado, nivel de confianza y aprobador, si hubo derivación).
RF15	El sistema debe permitir consultar indicadores de demanda, trámites más consultados, plazos vencidos y motivos de derivación para la autoridad o administrador.

Relación entre historias de usuario y requisitos funcionales

Historia de usuario	Requisitos funcionales relacionados
HU01 Consultar requisitos, costos y plazos	RF01, RF08
HU02 Orientación guiada para iniciar un trámite	RF02, RF12
HU03 Consultar estado del expediente	RF03, RF13
HU04 Atención por WhatsApp con voz y texto	RF04, RF05
HU05 Respuesta con cita del documento	RF08, RF14
HU06 Derivación a gestor humano	RF09, RF10
HU07 Bandeja de casos derivados	RF09, RF10
HU08 Actualización del catálogo de trámites	RF11
HU09 Validación de borradores de respuesta	RF10, RF14
HU10 Indicadores de demanda	RF15
HU11 Visualización de plazos vencidos	RF15
HU12 Indicadores de satisfacción y mejora	RF14, RF15

5. Atributos de calidad

Fuente: analisis-de-sistema/04-atributos-de-calidad.md

Atributos de calidad

Los atributos de calidad describen **cómo** debe comportarse el sistema, más allá de las funcionalidades que ofrece.

Escenario

La entidad atiende a miles de administrados a través de canales digitales. El asistente recibe consultas sobre requisitos, costos y plazos, solicitudes para iniciar trámites y preguntas sobre el estado de expedientes, a veces con voz y texto. Si la información que entrega es incorrecta o el sistema se cae en horas pico, el administrado pierde tiempo y la entidad pierde confianza. ¿Qué atributos de calidad resultan importantes?

Atributos de calidad identificados

ID	Atributo de calidad	Escenario de calidad
AC01	Exactitud	Toda respuesta sobre requisitos, costos o plazos debe estar sustentada en el documento normativo vigente. Cuando no se alcanza un nivel mínimo de confianza, el sistema debe derivar el caso a un gestor humano.
AC02	Disponibilidad	El canal de atención debe seguir recibiendo mensajes aun cuando los servicios de inferencia estén degradados. Si el proveedor de modelos no responde, el sistema debe entregar respuestas básicas del catálogo y derivar el resto.
AC03	Rendimiento	El gateway de canales debe devolver un código de seguimiento al administrado en menos de 200 ms, incluso bajo alta concurrencia.
AC04	Escalabilidad	El gateway, el bus de eventos y los workers deben escalar de forma independiente según la carga de cada etapa (tráfico de canales, transcripción, clasificación, generación).

ID	Atributo de calidad	Escenario de calidad
AC05	Privacidad y protección de datos	El sistema debe cumplir con la Ley 29733: enmascarar DNI y datos de contacto antes de enviarlos al proveedor externo, solicitar consentimiento y definir la retención de conversaciones.
AC06	Trazabilidad	Cada respuesta debe quedar registrada con la versión del documento citado, el nivel de confianza y, si hubo derivación, el gestor que aprobó la respuesta.
AC07	Mantenibilidad del conocimiento	Cuando cambia el TUPA o un documento normativo, el gestor de área debe poder actualizar el catálogo y reindexar el corpus sin desplegar código.
AC08	Accesibilidad e inclusión	El sistema debe ofrecer voz y texto, lenguaje claro y la opción de quechua si el público de la entidad lo necesita, además de cumplir con criterios de accesibilidad web (WCAG) en la aplicación ciudadana.
AC09	Interoperabilidad	El sistema debe integrarse con el sistema de gestión documentaria, los canales de atención (WhatsApp, web, SMS), el proveedor de modelos y, opcionalmente, con RENIEC y la pasarela de pagos, mediante capas anticorrupción.
AC10	Resiliencia	La caída del proveedor de modelos o del sistema documentario no debe impedir la atención: debe haber degradación controlada y caché de estados para consultas ya resueltas.

6. Restricciones del proyecto

Fuente: analisis-de-sistema/05-restricciones.md

Restricciones

Las restricciones son condiciones, reglas o limitaciones que deben respetarse durante el desarrollo del sistema. Pueden ser tecnológicas, organizacionales, legales o del proyecto.

Listado de restricciones

ID	Restricción	Descripción
RC01	Canales digitales	El sistema debe atender al administrado a través de canales digitales: WhatsApp, aplicación web y, opcionalmente, SMS para zonas con poca conectividad.
RC02	Marco normativo peruano	El sistema debe alinearse con el TUPA de la entidad, el TUO de la Ley 27444 (Ley del Procedimiento Administrativo General) y demás normas vigentes aplicables.
RC03	Protección de datos personales	El sistema debe cumplir con la Ley 29733 y su reglamento, incluyendo consentimiento, enmascaramiento, cifrado, retención de conversaciones y cláusulas de confidencialidad con el proveedor externo.
RC04	Integración con sistema documentario	El sistema debe integrarse con el sistema de gestión documentaria o mesa de partes virtual de la entidad para registrar expedientes y consultar su estado, mediante una capa anticorrupción.
RC05	Proveedor gestionado de modelos	El sistema debe apoyarse en un proveedor externo de modelos de lenguaje y voz, gestionado mediante contrato y con acuerdos de tratamiento de datos.
RC06	Catálogo TUPA versionado	El catálogo de trámites debe estar versionado y ser actualizable por el gestor de área, sin necesidad de desplegar código.

ID	Restricción	Descripción
RC07	Control de versiones	El código fuente y los archivos de documentación deben gestionarse con Git en un repositorio compartido.
RC08	Documentación como código	La documentación del sistema (diagramas, propuesta, análisis) debe versionarse junto con el código fuente.
RC09	Accesibilidad	La aplicación web ciudadana debe cumplir con criterios de accesibilidad WCAG y, cuando el público lo requiera, ofrecer soporte de quechua.
RC10	Idioma	La interfaz y las respuestas deben estar disponibles en español por defecto, con la opción de incluir quechua si la entidad lo define.

7. Drivers arquitectónicos

Fuente: analisis-de-sistema/06-driver-arquitectonicos.md

Drivers arquitectónicos

Los drivers arquitectónicos son los requisitos, atributos de calidad y restricciones que influyen significativamente en las decisiones de arquitectura del sistema.

Listado de drivers arquitectónicos

ID	Driver arquitectónico	Origen	¿Por qué influye en la arquitectura?
DA01	Toda respuesta sobre requisitos, costos o plazos debe sustentarse en el documento normativo vigente.	AC01 – Exactitud	Obliga a separar el componente generador del recuperador documental y a registrar la cita y la versión del documento en cada respuesta.
DA02	Las consultas de estado de expedientes deben resolverse con datos reales del sistema documentario, no con texto generado.	AC01 – Exactitud / RF03	Obliga a enrutar la consulta directamente al Servicio de trámites, evitando el paso por el modelo generativo para evitar alucinaciones sobre casos concretos.
DA03	El gateway de canales debe responder en menos de 200 ms y absorber picos de concurrencia.	AC02 – Disponibilidad / AC03 – Rendimiento	Obliga a un gateway sin estado, a un bus de eventos que desacople la ingesta de la inferencia y a workers que escalen de forma independiente.
DA04	El sistema debe seguir aceptando mensajes aunque el proveedor de modelos o el sistema documentario estén degradados.	AC02 – Disponibilidad / AC10 – Resiliencia	Obliga a un diseño con degradación controlada: respuestas básicas del catálogo, derivación al gestor humano y caché de estados.
DA05	El sistema debe proteger los datos personales conforme a la Ley 29733.	AC05 – Privacidad / RC03	Obliga a enmascarar DNI y datos de contacto antes de enviarlos al proveedor externo, a registrar consentimiento y a definir retención de conversaciones.

ID	Driver arquitectónico	Origen	¿Por qué influye en la arquitectura?
DA06	El sistema debe integrarse con el sistema de gestión documentario mediante una capa anticorrupción.	RC04 – Integración con sistema documentario	Obliga a aislar el modelo interno de los expedientes del esquema del proveedor para evitar acoplamiento y facilitar cambios.
DA07	El catálogo de trámites (TUPA) debe poder actualizarse sin desplegar código.	AC07 – Mantenibilidad del conocimiento / RC06	Obliga a separar el corpus normativo del código, con versionado y alertas de vigencia, y a reindexar automáticamente al actualizarse.
DA08	Cada respuesta debe quedar trazada (versión del documento, confianza, gestor aprobador).	AC06 – Trazabilidad	Obliga a persistir un registro de auditoría por cada respuesta automática y por cada derivación aprobada.
DA09	El sistema debe atender al administrado por WhatsApp, web y SMS con el mismo flujo conversacional.	RC01 – Canales digitales / RF04	Obliga a un gateway único que abstraiga los canales y a que la lógica de negocio no dependa de un canal específico.
DA10	La aplicación web ciudadana debe ser accesible y, cuando aplique, ofrecer quechua.	AC08 – Accesibilidad e inclusión / RC09	Obliga a criterios WCAG, lenguaje claro y opción multilingüe desde el inicio del diseño de la interfaz.


8. Arquitectura inicial del sistema

Fuente: *arquitectura/arquitectura-inicial.md*

Arquitectura inicial del sistema

1. Arquitectura por capas y contenedores

A partir del análisis del sistema (actores, requisitos, atributos de calidad, restricciones y drivers arquitectónicos), se propone una arquitectura organizada en **capas y contenedores**, inspirada en la estructura de WILLAKUY. Los drivers de exactitud, disponibilidad y privacidad llevan a separar claramente la ingesta, la inferencia, el catálogo de trámites y los datos.



Sistemas externos:

Sistema de gestión documentaria (mesa de partes)
Proveedor de modelos de lenguaje y voz
RENIEC / PIDE (opcional) · Pasarela de pagos (opcional)

Capa / Contenedor	Pregunta que responde
Actores	¿Quiénes usan el sistema?
Presentación	¿Cómo interactúan el administrado y los gestores?
Gateway de canales	¿Cómo entran y salen los mensajes?
Bus de eventos	¿Cómo desacoplamos la ingesta de la inferencia?
Lógica de negocio	¿Qué hace el asistente y cómo decide?
Datos	¿Dónde se guarda el conocimiento y la trazabilidad?
Sistemas externos	¿Con qué servicios se integra la entidad?

Responsabilidades por contenedor

- **Gateway de canales:** API sin estado que recibe mensajes de WhatsApp, web y SMS, valida, encola en el bus y devuelve un código de seguimiento al administrado en menos de 200 ms.
- **Bus de eventos:** desacopla la ingesta de la inferencia con etapas (transcripción, clasificación, respuesta, notificación), de modo que un pico o una caída de un worker no afecta al canal.
- **Workers de procesamiento:** ejecutan la transcripción de voz, la clasificación de intención, la extracción de entidades y la generación de respuesta con recuperación documental. Escalan por separado.
- **Servicio de trámites:** expone el catálogo TUPA estructurado (requisitos, costos, plazos, base legal, área responsable) y consulta el estado real de expedientes en el sistema documentario mediante una capa anticorrupción. Es el camino obligatorio para responder sobre el estado de un expediente, sin pasar por el modelo generativo.
- **Gestor de diálogo guiado:** máquina de estados para flujos como "quiero iniciar el trámite X", que solicita datos, verifica requisitos, adjunta documentos y entrega el expediente prellenado.
- **Servicio de notificaciones:** responde por el canal de origen y avisa al administrado cuando cambia el estado de su expediente.
- **Aplicación web ciudadana:** interfaz accesible (WCAG) con el mismo flujo que el canal conversacional.
- **Backoffice institucional:** bandeja de casos derivados, aprobación de respuestas, edición del catálogo, tablero de demanda y plazos.
- **Almacenamiento:** base relacional con extensión vectorial (catálogo y casos), caché en memoria (sesión y respuestas frecuentes) y repositorio de documentos oficiales.

2. Diagrama de arquitectura

El código fuente Mermaid también se encuentra disponible en [/images/arquitectura_sistema.mmd](../images/arquitectura_sistema.mmd) para poder reutilizarlo en otros documentos.

```
flowchart TD
```

```
%% =====
%% ACTORES
%% =====
subgraph ACTORES["ACTORES"]
```

```

    Administrado["Administrado"]
    Gestor["Gestor de área"]
    Autoridad["Autoridad / Administrador"]
end

%% =====
%% PRESENTACIÓN
%% =====
subgraph PRESENTACION["PRESENTACIÓN"]
    WebApp["App Web Ciudadana (WCAG)"]
    Backoffice["Backoffice Institucional"]
end

%% =====
%% GATEWAY DE CANALES
%% =====
subgraph GATEWAY["GATEWAY DE CANALES"]
    Gateway["API sin estado (WhatsApp · Web · SMS)"]
end

%% =====
%% BUS DE EVENTOS
%% =====
subgraph BUS["BUS DE EVENTOS"]
    Colas["Colas por etapa: transcripción · clasificación · respuesta · notifica
ción"]
end

%% =====
%% LÓGICA DE NEGOCIO
%% =====
subgraph NEGOCIO["LÓGICA DE NEGOCIO"]
    Normalizador["Normalizador de texto"]
    Clasificador["Clasificador de intención"]
    Extractor["Extractor de entidades"]
    Enrutador["Enrutador por intención"]
    Recuperador["Recuperador (corpus normativo)"]
    Generador["Generador con cita"]
    Confianza["Evaluador de confianza"]
    Tramites["Servicio de trámites (TUPA · estado)"]
    Dialogo["Gestor de diálogo guiado"]
    Notificaciones["Servicio de notificaciones"]
end

%% =====
%% DATOS
%% =====
subgraph DATOS["DATOS"]
    BD["BD relacional + extensión vectorial"]
    Cache["Caché en memoria (sesión y estados)"]
    Docs["Repositorio de documentos oficiales"]
end

%% =====
%% SISTEMAS EXTERNOS
%% =====
subgraph EXTERNOS["SISTEMAS EXTERNOS"]
    Docu["Sistema de gestión documentaria"]

```

```

    LLM["Proveedor de modelos (lenguaje y voz)"]
    Reniec["RENIEC / PIDE (opcional)"]
    Pagos["Pasarela de pagos (opcional)"]
end

%% =====
%% FLUJO PRINCIPAL
%% =====
ACTORES --> PRESENTACION
PRESENTACION --> GATEWAY
GATEWAY --> BUS
BUS --> NEGOCIO
NEGOCIO --> DATOS

%% =====
%% INTEGRACIONES
%% =====
Enrutador -->|"información"| Recuperador
Enrutador -->|"estado"| Tramites
Enrutador -->|"iniciar trámite"| Dialogo
Recuperador --> Generador
Generador --> Confianza
Confianza -->|"confianza OK"| Notificaciones
Confianza -->|"deriva"| Backoffice
Backoffice -->|"aprueba"| Notificaciones
Tramites -->|"registra / consulta expediente"| Docu
Notificaciones -->|"responde por canal"| GATEWAY
Dialogo -->|"envía expediente"| Docu
LLM -->|"transcripción · clasificación · generación"| NEGOCIO
Pagos --> Dialogo
Reniec --> Dialogo

%% =====
%% ESTILOS
%% =====
classDef darkBox fill:#1e1e1e,stroke:#ffffff,stroke-width:2px,color:#ffffff
class ACTORES,PRESENTACION,GATEWAY,BUS,NEGOCIO,DATOS,EXTERNOS darkBox
class Administrado,Gestor,Autoridad,WebApp,Backoffice,Gateway,Colas,Normalizador
,Clasificador,Extractor,Enrutador,Recuperador,Generador,Confianza,Tramites,Dialogo,Notificaciones,BD,Cache,Docs,Docu,LLM,Reniec,Pagos darkBox

```

3. Descripción

La arquitectura inicial se apoya en cuatro ideas clave, derivadas de los drivers arquitectónicos:

- **Ingesta desacoplada:** el gateway de canales y el bus de eventos garantizan que el administrado siempre reciba un acuse rápido, aunque los workers estén saturados o caídos (DA03, DA04).
- **Exactitud sobre fluidez:** las consultas de estado se enrutan directamente al Servicio de trámites y al sistema documentario, sin pasar por el modelo generativo, para evitar alucinaciones sobre expedientes concretos (DA02). Las consultas de información sí pasan por el recuperador y el generador, pero siempre con cita normativa y evaluación de confianza (DA01).
- **Conocimiento versionado:** el catálogo TUPA y el corpus normativo viven en el Servicio de trámites y en el repositorio de documentos, de modo que el gestor de área puede actualizarlos sin desplegar código (DA07).

- **Privacidad por diseño:** los datos personales se enmascaran antes de salir al proveedor externo y la trazabilidad de cada respuesta se persiste en la base relacional (DA05, DA08).